

Classification de la Qualité du Vin

Ahmad TAY, Ahmed-Ghazi BLAIECH, Hassan SHRAIM

Cours : Machine Learning 1

2026-2027

1 Contexte et Objectif

La qualité d'un vin est influencée par de nombreux paramètres physico-chimiques tels que l'acidité, le pH, le taux d'alcool ou encore la teneur en sucre résiduel. L'objectif de ce projet est de développer un modèle de **classification supervisée** capable de prédire la **qualité du vin** (sur une échelle de 0 à 10, ou sous forme binaire : *bon/mauvais*) à partir de ces caractéristiques mesurables. Le jeu de données à utiliser se trouve **ICI**.

2 Modalités du projet

2.1 Prétraitement des données

- Chargement des données et statistiques descriptives.
- Gestion des valeurs manquantes et détection des valeurs aberrantes.
- Encodage correct des variables catégorielles (si présentes).
- Transformation du problème en classification binaire (*qualité ≥ 7 donc bon vin*).
- Analyse de la distribution des classes pour vérifier l'équilibre du jeu de données.
- Analyse des corrélations entre les variables.
- Visualisations (matrice de corrélation, histogrammes, boxplots).
- Utilisation de méthodes de sélection de variables basées sur les méthodes vues en cours.

2.2 Modélisation et évaluation

- Modèles envisagés : régression logistique, k-NN, arbre de décision, Naive Bayes, SVM.

- Justification du choix des modèles selon :
 - Leurs propriétés théoriques (linéaires vs non linéaires).
 - Leur adaptabilité au type de données (distributions continues, bruit, etc.).

2.3 Évaluation des modèles

- Évaluation des modèles à l'aide de métriques pertinentes :
 - Accuracy, précision, rappel, F1-score.
 - Matrice de confusion.
 - Courbe ROC et AUC.
- Comparaison des performances et interprétation des résultats.
- Identification du modèle le plus performant selon un compromis biais/variance.

2.4 Optimisation des hyperparamètres

- Utilisation de techniques d'optimisation telles que :
 - **Grid Search** : recherche exhaustive sur une grille d'hyperparamètres.
 - **Random Search** : recherche aléatoire pour un gain de temps.
- Évaluation des modèles optimisés via validation croisée (k-fold).

2.5 Bonus

- Mettre votre solution sur github ou gitlab
- Ajouter des tests unitaires
- Containeriser votre code pour qu'il être exécuté facilement par un tiers
- Mettre en place une application web qui donne la prédiction pour une observation donnée en entrée

3 Livrables attendus

- Rapport technique détaillant les étapes de traitement, d'analyse et de modélisation.
- Notebook Python (Jupyter/Colab) contenant le code complet.